Gerçek Zamanlı Fizyolojik Stres Tespitinde Açıklanabilirliğin Hesaplama Maliyeti: Uç ve Sis Yerleşiminde Uçtan Uca Ölçüm

Sena Cindioğlu
Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
İstanbul, Türkiye

Meryem Eldemery
Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
İstanbul, Türkiye

Hafiza İrem Türkmen Çilingir
Bilgisayar Mühendisliği Bölümü
Yıldız Teknik Üniversitesi
İstanbul, Türkiye

***Özet*—Fizyolojik sinyallerden stres tespiti literatüründe sınıflandırma başarımı doyuma yaklaşmış, açıklanabilir yapay zekâ (XAI) yöntemleri de yaygınlaşmıştır. Buna karşılık açıklama üretmenin *hesaplama maliyeti* neredeyse hiç ölçülmemektedir: yaygın XAI değerlendirme çerçeveleri çalışma süresini kapsam dışı bırakmakta, WESAD üzerinde XAI uygulayan çalışmalar ise pencere başına açıklama gecikmesi bildirmemektedir. Bu çalışma, bitirme projesinde üretilmiş ve dondurulmuş bir stres sınıflandırıcısını gerçek zamanlı bir yeniden oynatma (replay) sistemine yerleştirerek bu boşluğu doldurur. Sistem, sensör istemcisi ile çıkarım sunucusunu gerçek bir TCP bağlantısıyla ayırır; gecikme, kuyruk gecikmesi, çalışma süresi, yanıt süresi, seğirme, bant genişliği ve kaynak kullanımı olmak üzere yedi metriği yüksek çözünürlüklü saatlerle, periyodik saat yeniden senkronizasyonu altında ölçer. Bölge tabanlı LIME ve SHAP GradientExplainer açıklayıcıları sunucunun içine, tahminle aynı iş parçacığına yerleştirilmiş; hiperparametreleri sadakat, monotonluk, duyarlılık ve karmaşıklık ölçütleriyle birlikte taranmıştır. Ayrı bir fiziksel makinede, Wi-Fi üzerinden yapılan uçtan uca ölçümlerde açıklayıcı kapalıyken yanıt süresi medyanı 10,6 ms iken, en pahalı yapılandırmada 1456,2 ms'ye, yani 137 katına çıkmaktadır; sunucu bellek ayak izi 210 MB'den 464 MB'ye yükselmektedir. Ucuz çalışma noktaları (SHAP 442,6 ms, LIME 645,2 ms) literatürdeki bir saniyelik gerçek zamanlılık sınırının altında kalmaktadır. Bu sayılar, güven eşikli seçici açıklama mekanizmasının niçin gerekli olduğunu niceliksel olarak ortaya koymaktadır.**

***Index Terms*—açıklanabilir yapay zekâ, stres tespiti, WESAD, sis bilişim, gerçek zamanlı sistemler, hesaplama maliyeti, SHAP, LIME**

I. Giriş

Giyilebilir sensörlerden sürekli stres izleme, sağlık ve insan–bilgisayar etkileşimi uygulamaları için olgunlaşmış bir problemdir. WESAD [1] gibi ölçüt veri kümeleri üzerinde %90'ın üzerinde doğruluk rutin biçimde bildirilmekte [2], model kararlarının şeffaflığı için de SHAP [4], LIME [3] ve Integrated Gradients [5] gibi post-hoc açıklayıcılar yaygın olarak kullanılmaktadır.

Ancak bu iki gelişme birbirinden bağımsız ilerlemiştir. Sınıflandırma başarımını raporlayan çalışmalar açıklamanın maliyetini, açıklama üreten çalışmalar da sistemin zamanlamasını ölçmemektedir. Nauta ve ark.'nın Co-12 değerlendirme çerçevesi bu dışlamayı açıkça yapar: *"çalışma süresi gibi, açıklama kalitesini doğrudan etkilemeyen ölçütler hariç tutulmuştur"* [7]. Quantus, OpenXAI ve XAI-Bench gibi kıyaslama araçları da süre sütunu içermez. Sonuç olarak "açıklama maliyeti" için ne standart bir metrik, ne standart bir birim, ne de liderlik tablolarında bir yer vardır.

Bu boşluk çevrimdışı bir çalışmada zararsızdır; gerçek zamanlı bir sistemde ise belirleyicidir. Tek bir açıklama, pencere güncelleme aralığından uzun sürüyorsa sistem kuyruk biriktirir ve gerçek zamanlı olmaktan çıkar. Franco de la Peña ve ark. bu sınırı açıkça koyar: *"pencere başına bir saniyeden fazla süren bir XAI yöntemi gerçek zamanlı dağıtıma uygun değildir"* [8].

Bu rapor, bir bitirme projesi kapsamında üretilmiş ve dondurulmuş bir stres sınıflandırıcısını temel alarak bu eksiği kapatan ölçüm çalışmasını belgelemektedir. Katkılar şunlardır:

1) **Sızıntısız çevrimiçi değerlendirme.** Çevrimdışı eğitimde kullanılan denek bazlı z-skor normalizasyonunun nedensel (yalnızca geçmişi gören) karşılığı uygulanmış ve doğruluk üzerindeki etkisi ölçülmüştür.
2) **Aşama bazlı gerçek zamanlı profil.** Yeniden örnekleme, ön işleme, tensör hazırlığı, çıkarım ve son işleme aşamaları ayrı ayrı, tekrarlı ve dönüşümlü koşularla, koşu içi ve koşu arası dağılımlar ayrıştırılarak ölçülmüştür.
3) **Yedi metrikli taşıma katmanı ölçümü.** İstemci ve sunucu gerçek bir TCP bağlantısıyla ayrılmış, iki bağımsız yüksek çözünürlüklü saat arasında periyodik yeniden senkronizasyon ve doğrusal ara değerleme uygulanmıştır.
4) **Açıklama maliyetinin taşıma metrikleriyle aynı bütçede raporlanması.** Bilgimiz dahilinde, pencere başına açıklama gecikmesini kuyruk gecikmesi, seğirme, bant genişliği ve sunucu kaynak kullanımıyla birlikte veren bir çalışma yoktur.
5) **Açıklayıcı hiperparametre taraması.** LIME örnek sayısı, bölge sayısı ve çekirdek genişliği ile SHAP arka plan boyutu, örnek sayısı ve arka plan seçim yöntemi; süre *ve* dört kalite ölçütü birlikte verilerek taranmıştır.

Güven eşikli seçici açıklama mekanizması sisteme entegre edilmiş ve iki uç durum (hiç açıklama / her pencerede

Tablo I
BITIRME PROJESINDEKI EN IYI YAPILANDIRMALAR (ÖZET)

Model	Pencere	Doğruluk (%)	F1 (%)
CNN	30 s	87,63	86,29
CNN–LSTM	30 s	86,08	83,66
TranSensFusers	10 s	**91,13**	**90,40**

Tablo II
BITIRME PROJESINDEKI XAI DEĞERLENDIRMESI (TRANSENSFUSERS, 10 S PENCERE)

Ölçüt	SHAP	LIME	IG	En iyi
Sadakat (ekleme)	0,4048	0,4282	**0,4402**	IG
Sadakat (silme)	0,2613	0,2153	**0,2055**	
Monotonluk ihlali	**0,4047**	0,5079	0,5300	SHAP
Duyarlılık	**0,0038**	0,0116	0,0053	SHAP
Karmaşıklık	0,4674	**0,0066**	0,4585	LIME

Ekleme eğrisinde yüksek, diğer üç ölçütte düşük değer iyidir.

açıklama) uçtan uca ölçülmüştür. Ara eşiklerin taraması ve güven kalibrasyonu devam eden iştir; Bölüm IX'de açıkça belirtilmiştir.

II. ÖNCEKI AŞAMA: ÇEVRIMDIŞI SINIFLANDIRMA VE AÇIKLANABILIRLIK

Bu bölüm, üzerine inşa edilen bitirme projesinin [21] kısa özetidir.

WESAD veri kümesinde [1] göğüs (RespiBAN) ve bilek (Empatica E4) sensörlerinden gelen EDA, EKG, EMG, solunum, deri sıcaklığı, kan hacmi nabzı ve üç eksenli ivmeölçer sinyalleri zaman pencerelerine bölünerek stres / stres dışı olarak sınıflandırılmıştır. Üç mimari karşılaştırılmıştır: bir evrişimsel sinir ağı (CNN), hibrit bir CNN–LSTM ve Transformer tabanlı TranSensFusers [2]. Sınıf dengesizliği odak kaybı (focal loss) [6] ile ele alınmış, değerlendirme denek bağımsız Leave-One-Subject-Out protokolüyle yapılmıştır. Pencere boyutu her mimari için ayrıca taranmış; en iyi sonuç 10 saniyelik pencerelerle eğitilen TranSensFusers modelinden elde edilerek %91,13 doğruluk ve %90,40 F1-skoru elde edilmiştir (Tablo I).

En iyi modele SHAP, LIME ve Integrated Gradients (IG) uygulanmış; açıklamalar sadakat, monotonluk, duyarlılık ve karmaşıklık olmak üzere dört nicel ölçütle değerlendirilmiştir (Tablo II). SHAP en dengeli ve en kararlı açıklamaları üretmiş, IG tamamlayıcı gradyan tabanlı bilgi sağlamış, LIME ise seyrek fakat daha az kararlı açıklamalar vermiştir. Kanal düzeyinde atıf analizinde elektrodermal aktivite ve kardiyak sinyaller baskın katkı sağlayarak fizyolojik beklentiyi doğrulamıştır.

Bu çalışmanın çıkış noktası. Bitirme projesinin bütün ölçümleri çevrimdışıdır: tüm kaydın istatistiğiyle normalize edilmiş pencereler, toplu çıkarım, ağ yok, süre ölçümü yok. Dolayısıyla "model yanıtı 100 ms altı, açıklama 2 s altı" biçimindeki gereksinimler *iddia* edilmiş ama test edilmemiştir. Bu rapor tam olarak bu gereksinimleri ölçülebilir hale getirir.

Kapsam daraltması. Gerçek zamanlı çalışmada tek bir model (TemporalCNN) ve iki açıklayıcı (SHAP, LIME) kullanılmaktadır. Gerekçe, karşılaştırmanın sabit bir hesap bütçesi üzerinde yapılabilmesidir: TranSensFusers ve CNN–LSTM'in eklenmesi açıklama maliyetindeki farkı model maliyetindeki farkla karıştırırdı. Integrated Gradients, SHAP GradientExplainer ile aynı gradyan tabanlı maliyet sınıfında olduğu için kapsam dışı bırakılmıştır.

Tablo III
LITERATÜRDE BILDIRILEN AÇIKLAMA SÜRELERI

Çalışma	Ölçülen	Donanım / girdi
ShaTS [8]	Sınır: >1 s/pencere gerçek zamanlı değil; KernelSHAP sık sık aşıyor	i7-14700K + RTX 4080; girdi 10×69
XAI-on-RAN [10]	Taban 5,3 ms; SHAP (m=16) $\approx +15$ ms	A100; 5 boyutlu girdi
Taguta ve ark. [11]	Koşullu SHAP $+195$ ms, $+\%28$ CPU, toplam $\approx$555 ms	Raspberry Pi 4, 24 günlük canlı dağıtım
Das ve ark. [12]	LIME 5,91 s; SHAP 695,2 s	i7-6700K; 33 sensör $\times$ 30 adım LSTM
Warnecke ve ark. [13]	KernelSHAP 9,1 s; LIME 0,03–0,74 s	Xeon E5; MLP/CNN
FastSHAP [14]	1000 görüntü: FastSHAP 0,04 dk; KernelSHAP 453–1089 dk	V100 + 8 çekirdek

III. İLGILI ÇALIŞMALAR

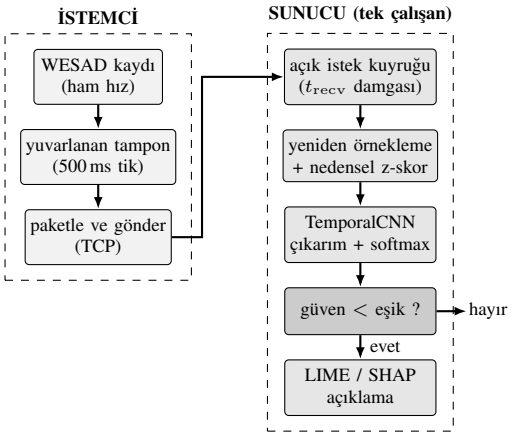
A. Sis mimarisinde fizyolojik izleme

Erzurumluoğlu ve ark. [9], DREAMER veri kümesi üzerinde duygu tanımayı bir sis (fog) mimarisine yerleştirmiş ve gecikme, kuyruk gecikmesi, çalışma süresi, yanıt süresi, seğirme, bant genişliği ve kaynak kullanımı olmak üzere yedi metriği raporlamıştır. Bu çalışma, sistem ölçüm çerçevemizin doğrudan referansıdır; aynı yedi metrik, aynı tanımlarla kullanılmıştır. Farklar ikidir: görev (stres, WESAD) ve eklenen boyut (açıklama maliyeti).

B. Açıklama maliyeti ölçümleri

Açıklayıcıların çalışma süresini raporlayan çalışmalar azdır ve büyük ölçüde fizyolojik alan dışındadır. Tablo III doğrulanabilmiş değerleri toplar. Değerlerin donanım ve girdi boyutuna aşırı duyarlı olduğuna dikkat edilmelidir: aynı yöntem (KernelSHAP) bir çalışmada saniyeler, başka bir çalışmada dakikalar sürmektedir.

Fizyolojik sinyal tarafında durum daha çarpıcıdır. Almadhor ve ark. [15] tam olarak bizim veri kümesi ailemizi (WESAD ve DREAMER) ve model ailemizi (1B-CNN) kullanmakta, üstelik Grad-CAM ve Integrated Gradients uygulamaktadır; buna karşın çıkarım süresi, XAI süresi, bellek veya donanım bilgisi vermemektedir. Benzer biçimde El Rashidy ve ark.



Şekil 1. Sistem akışı. Açıklama, tahminle aynı çalışanda ve çalışma süresinin *içinde* üretilir; ayrı bir iş parçacığına atılsaydı maliyeti ölçülemezdi.

[16] sis mimarisinde LIME ve Grad-CAM ile duygu tanıma yapmakta, yine de çıkarım başına gecikme ya da açıklama maliyeti raporlamamaktadır.

C. Seçici ve koşullu açıklama

Hesabı güvene göre dağıtma fikri yeni değildir. BranchyNet [18] ve Berestizshevsky ve Even [19] softmax güvenine göre çıkarımı erken keser. Açıklama tarafında Paes ve ark. [17] bütçeli seçici açıklama önerir; kapı kararını ucuz açıklayıcının belirsizliği verir. Artelt ve ark. [20] yalnızca reddedilen örnekler için açıklama üretir; gerekçeleri epistemiktir ve süre ölçmezler. Taguta ve ark. [11] SHAP'i koşullu tetikleyen, bilgimiz dahilinde donanım üzerinde ölçülmüş tek sistem çalışmasıdır.

Dolayısıyla bu çalışma *mekanizmayı* yeni diye sunmamaktadır. Katkı, mekanizmanın sürekli gerçek zamanlı fizyolojik izleme bağlamında deneysel olarak karakterize edilmesi ve açıklama maliyetinin taşıma katmanı metrikleriyle aynı bütçede raporlanmasıdır.

D. Boşluk

Alan üç ayrık gruba bölünmüştür: (i) sistem metriklerini ölçen, XAI içermeyen çalışmalar [9]; (ii) XAI maliyetini ölçen, ağ metriği vermeyen çalışmalar [8], [10]; (iii) fizyolojik sinyalde XAI uygulayan, hiç maliyet vermeyen çalışmalar [15], [16]. Bu rapor üçünün kesişiminde konumlanmaktadır.[1]

IV. Sistem Tasarımı

Sistemin genel akışı Şekil 1'de verilmiştir.

A. Model ve pencereleme

Sınıflandırıcı, çevrimdışı aşamada seçilip dondurulmuş bir TemporalCNN'dir: iki evrişim bloğu (`[32, 128]` filtre, çekirdek boyu 9, her blokta BatchNorm–ReLU–MaxPool–Dropout), ardından global ortalama havuzlama ve iki tam bağlı katman. Toplam 49 890 parametre içerir. Girdi 14 kanallı, 64 Hz'e indirgenmiş 10 saniyelik bir penceredir (640×14); pencereler %50 örtüşmeyle, yani 5 saniyede bir üretilir. Model 13 denekle eğitilmiş, S11 ve S14 tutulmuş (held-out) denek olarak ayrılmıştır; çevrimdışı ağırlıklı F1 değeri 0,9386'dır.

Kanal sırası eğitim ardışık düzeniyle birebir aynı olmak zorundadır (önce göğüs sekiz kanal, sonra bilek altı kanal). Sıra bozulduğunda doğruluğun 1,00'den 0,52'ye düştüğü gözlenmiş, bu nedenle sıra kod içinde açıkça belgelenmiştir.

B. Sızıntısız çevrimiçi normalizasyon

Çevrimdışı eğitimde veri denek bazlı `StandardScaler` ile normalize edilmişti. Gerçek zamanlı bir sistemde bu doğrudan kullanılamaz: bir deneğin tüm kaydının istatistiğini bilmek geleceğe sızmaktır. İki sızıntısız alternatif uygulanmış ve ölçülmüştür:

- **`running`:** Welford algoritmasıyla, yalnızca o ana kadar görülmüş veriden nedensel ortalama ve standart sapma. İstatistik güncelleme maliyeti her tikte ödenir ve dürüstlük gereği pencerenin ön işleme süresine eklenir.
- **`fixed`:** Yalnızca eğitim deneklerinden hesaplanmış tek bir sabit ortalama ve standart sapma. Yeni kullanıcı hakkında hiçbir şey bilinmeyen katı dağıtım senaryosuna karşılık gelir.

İki uzayın ürettiği pencereler ölçülmüştür: bağıl L2 farkı 0,77, standart sapma 1,00'e karşı 1,25'tir. Yani nedensel ve denek bazlı normalizasyon *aynı girdi uzayını vermez*. Bu, XAI ölçümlerinin hangi uzayda yapılması gerektiğini belirleyen kritik bulgudur (Bölüm VI-F).

C. İki ardışık düzen yolu

Yeniden örneklemenin nerede yapıldığı bir tasarım kararıdır ve ölçüme doğrudan girer:

- **`prepared`:** Tüm kayıt, yeniden oynatma başlamadan önce 64 Hz'e indirgenir; yeniden örnekleme ölçümün *dışında* kalır.
- **`native`:** Her sensör kendi hızında akar (göğüs 700 Hz, bilek 32/64/4 Hz), indirgeme sunucuda her pencerede yapılır ve *ölçülür*.

Gerçek bir sistemde sensör ham hızında veri gönderir; dolayısıyla `native` gerçekçi olan yoldur ve tüm ana sonuçlar bu yolda üretilmiştir.

D. İstemci–sunucu ayrımı

Erken aşamalarda istemci ve sunucu aynı süreçte çalışıyordu; bu, ağ kaynaklı metriklerin tanım gereği sıfır olması demekti. `serving/` paketi ikisini gerçek bir TCP bağlantısıyla ayırır: `protocol.py` tel formatını, çerçevelemeyi ve saat senkronizasyonunu; `server.py` açık istek kuyruğunu ve tek çalışanı; `client.py` ham hızda gönderen sensör istemcisini tanımlar. Sunucu WESAD verisine ihtiyaç duymaz; veri tamamen istemcide kalır ve sunucuya yalnızca ham sinyal parçaları akar.

Açık istek kuyruğu neden gerekli. İlk sürümde paket okunur okunmaz aynı yerde işleniyordu; t_{start} ile t_{recv} bitişik olduğu için kuyruk gecikmesi her zaman sıfıra yakın

[1] Bu bölümün hazırlığında kullanılan iç literatür notlarında, doğrulanamayan veya kendi içinde tutarsız sayılar içeren kaynaklar işaretlenmiş ve kaynakçaya alınmamıştır.

okunuyor ve bekleme süresi gecikmenin içinde gizleniyordu. Şimdi okuyucu görev paketi alıp varış zamanını damgalar ve ortak kuyruğa koyar; tek çalışan kuyruğu sırayla boşaltır. İki istemciyle p99 kuyruk gecikmesi 0,37 ms'den 5,50 ms'ye çıkmıştır, yani metrik artık gerçekten bekleme ölçmektedir.

E. Saat katmanı ve kayma düzeltmesi

İlk sürüm `time.time_ns()` kullanıyordu. Windows'ta bu sayacın çözünürlüğü ölçülmüş ve 15,6 ms çıkmıştır. Geri döngü (loopback) gecikmesi 0,1 ms mertebesinde olduğundan gecikme medyanı tam sıfır okuyordu; metrik tamamen anlamsızdı. `perf_counter_ns` 100 ns çözünürlük verir, ancak referans noktası sürece özeldir. Bu nedenle bağlantı başında NTP mantığıyla saat farkı ölçülür: on iki PING/PONG turu atılır ve en düşük gidiş-dönüş süresine sahip tur seçilir.

Tek bir ölçüm uzun koşularda yetmez: iki kristal aynı hızda tiklemediği için fark zamanla kayar. 87 dakikalık bir Wi-Fi koşusunda kayma, gecikme medyanını *negatife* düşürerek metriği geçersiz kılmıştır. Bu nedenle saat farkı varsayılan olarak 60 saniyede bir yeniden ölçülür ve her paketin gecikmesi iki ölçüm arasında doğrusal ara değerlemeyle düzeltilir. Ölçüm, son cevap alındıktan sonraki sessiz anda dört turda yapılır. Özete toplam kayma ve kayma hızı (ppm) yazılır; ayrıca gecikme medyanı $(\text{yanıt} - \text{çalışma} - \text{kuyruk})/2$ ile karşılaştırılarak tutarlılık denetimi basılır.

Gecikme belirsizliği gidiş-dönüş süresinin yarısı kadardır: geri döngüde $\pm 0{,}13$ ms, Ethernet'te $\pm 0{,}25$–1 ms, Wi-Fi'da ± 1–10 ms. Wi-Fi'da tek yönlü gecikmenin hata payı, ölçülen değerin kendisiyle aynı mertebeye çıkabilir. Bundan *etkilenmeyen* metrikler çalışma süresi ve kuyruk gecikmesi (ikisi de sunucu saati) ile yanıt süresi ve seğirmedir (ikisi de istemci saati).

F. Ölçülen yedi metrik

Tanımlar referans çalışmayla [9] aynıdır:

- **Gecikme (latency):** paketin istemciden sunucuya ulaşması; iki saat, fark düzeltmesi gerektirir.
- **Kuyruk gecikmesi:** çalışan meşgulken kuyrukta bekleme; sunucu saati.
- **Çalışma süresi (execution):** ardışık düzenin çalışma süresi; sunucu saati. Açıklama üretildiğinde bu sürenin içindedir.
- **Yanıt süresi (response):** istemcinin gördüğü toplam süre; istemci saati.
- **Seğirme (jitter):** yanıt süresinin ardışık mutlak değişiminin ortalaması.
- **Bant genişliği:** gönderilen ve alınan bayt / süre.
- **Kaynak kullanımı:** sunucu tarafı CPU yüzdesi ve yerleşik bellek (RSS).

G. Açıklayıcılar

Açıklayıcılar sunucunun içinde, tek pencere üzerinde çalışacak biçimde yazılmıştır. Ortak arayüz `explain(pencere)` çağrısıyla (C, T) boyutlu bir atıf haritası döndürür. Pencere yönü iki farklı gösterimde dolaştığı için ($(640, 14)$ tampon yönü, $(14, 640)$ model yönü) dönüşüm kanal sayısına bakarak otomatik yapılır.

Bölge tabanlı LIME. Hazır `lime` paketi kullanılmamıştır: girdi $14 \times 640 = 8960$ değerlik bir zaman serisidir ve her örneği ayrı değişken saymak hem çok pahalı hem de yorumlanamazdır. Görüntüdeki "süper piksel"in buradaki karşılığı *zaman dilimi* $\times$ *kanal* bölgeleridir; örneğin 20 dilim $\times$ 14 kanal $=$ 280 bölge. Bir bölge kapatıldığında o kanalın o dilimi *kanalın kendi ortalamasıyla* değiştirilir. Sıfırlamak fizyolojik olarak anlamsız olurdu: normalize edilmiş sinyalde sıfır, o kanalın ortalama seviyesi değil kaydın ortalamasıdır. Maskeler sabit tohumla örneklenir, ağırlık $w = \sqrt{\exp(-d^2/\sigma^2)}$ üssel çekirdeğiyle verilir (d: kapalı bölge oranı, σ: çekirdek genişliği) ve katsayılar Ridge regresyonuyla çözülür. Maliyet, örnek sayısı $\times$ ileri geçiş olarak doğrusal büyür.

SHAP GradientExplainer. Arka plan kümesi bir kez üretilip diske yazılır (100 pencere, k-ortalamalar, S2–S5 denekleri-nden, sunucunun gördüğü nedensel uzayda). Gerekçe ikilidir: sunucuda her açılışta yeniden kümeleme saniyeler alır ve taramada kullanılan kümeyle birebir aynı sonucu vermez. Tohum sabitlenmiştir; aksi halde aynı pencere iki kez açıklandığında farklı atıf çıkar ve "girdiye duyarlılık" ölçütü yöntemin kendi rastgeleliğini de sayar. Bu ölçülmüştür: tohum sabitlenince SHAP'in duyarlılık değeri 0,139'dan 0,075'e düşmüş, yani farkın neredeyse yarısının yöntemin kendi gürültüsü olduğu görülmüştür.

Isınma. SHAP'in *ilk* çağrısı ölçüm makinesinde 12,4 saniye sürmüştür; sonraki çağrılar 0,85 saniyedir. Fark, grafik kurulumu ve önbellek ısınmasıdır. Isıtılmazsa bu 12 saniye ilk açıklamada tek çalışanı bloklar ve tüm kuyruk arkasında birikir. Bu nedenle açıklayıcı sunucu açılışında bir kez sahte bir pencereyle çalıştırılır ve ilk çağrı süresi rapora yazılır.

H. Açıklama kalitesi ölçütleri

Dört ölçüt, bitirme projesindekiyle aynı tanımlarla hesaplanır:

- **Silme (deletion):** bölgeler en önemliden başlayarak kanal ortalamasıyla kapatılır; eğri altındaki alanın *düşük* olması sadakat göstergesidir.
- **Ekleme (insertion):** taban çizgisinden başlanarak en önemli bölgeler eklenir; alanın *yüksek* olması iyidir.
- **Sadakat:** $\mathrm{AUC}_{\text{ekleme}} - \mathrm{AUC}_{\text{silme}}$.
- **Monotonluk:** ekleme eğrisinde azalmayan adımların oranı.
- **Duyarlılık:** girdiye $0{,}05\sigma$ ölçeğinde Gauss gürültüsü eklendiğinde atıfın normalize L2 değişimi; *düşük* iyidir.
- **Kendi-kararsızlığı:** aynı pencere yeniden açıklandığında atıfın değişimi. Deterministik bir yöntemde sıfırdır. Bu ayrı raporlanmazsa "kararsız yöntem" ile "girdiye duyarlı yöntem" birbirine karışır.

I. Güven eşikli seçici açıklama

Sunucu, softmax çıktısının maksimumunu güven olarak kullanır ve eşiğin altında kalan pencerelerde açıklama üretir:

Tablo IV
ÖLÇÜM ORTAMLARI

Yerleşim	Sunucu donanımı	Bağlantı
Geri döngü	İstemciyle aynı makine (Intel, 20 çekirdek, 16 GB, Win 10)	127.0.0.1
Uç (ortak)	Aynı makine, ayrı süreç	127.0.0.1
Sis	Ayrı fiziksel makine (Intel, 12 çekirdek, 16 GB, Win 11, PyTorch 2.14 CPU)	Wi-Fi, ev yönlendiricisi

$$\text{açıkla} = \begin{cases} \text{hayır}, & \tau \le 0 \\ \text{evet}, & \tau \ge 1 \\ c < \tau, & \text{aksi halde} \end{cases} \quad (1)$$

burada c güven, τ eşiktir. $\tau = 0$ ve $\tau = 1$ uç durumlar kasıtlı olarak ayrı ele alınır; bunlar kontrol koşularıdır (XAI'siz taban ve en pahalı durum). $\tau \ge 1$ karşılaştırması ayrıca ele alınmıştır çünkü softmax çıktısı tam 1,0 okuyabildiğinde "$c < 1{,}0$" kuralı nadiren de olsa pencere atlıyordu.

Açıklama, tahminle aynı çalışanda ve çalışma süresinin içinde üretilir. Ayrı bir iş parçacığına atılsaydı maliyeti görünmez olurdu; deneyin bütün amacı o maliyeti ölçmektir.

V. DENEY DÜZENEĞI

A. Donanım ve ağ

Üç yerleşim ölçülmüştür (Tablo IV). "Uç" terimi burada *ortak yerleşim* anlamındadır: istemci ve sunucu aynı makinede, ayrı süreçlerde, geri döngü üzerinden haberleşir. Giyilebilir cihaz anlamında kullanılmamaktadır.

Önemli bir sınırlılık. İki normal bilgisayar arasındaki deney gerçek ağ gecikmesini, seğirmeyi ve bant genişliğini verir. Ancak bu bir *dağıtık yerleşim* ölçümüdür, bir *sis düğümü* ölçümü değildir: sis tanımındaki kaynak kısıtı yoktur. Rapor boyunca bu ayrım korunmuştur.

B. Ölçüm kuralları

Aşağıdaki kurallar bütün koşularda geçerlidir:

1) **Yığın boyutu 1.** Gerçek kullanıcı tek pencere gönderir.
2) **Isınma hariç.** İlk 15 pencere (tek süreçli koşularda 30) istatistiğe girmez.
3) **Ortalama, medyan, p95, p99 birlikte.** "En hızlı çalışma" raporlanmaz.
4) **Tekrarlı ve dönüşümlü.** Karşılaştırmalarda üç veya dört tekrar, sıra A, B, A, B biçimindedir; böylece işlemci ısınmasından kaynaklanan kayma tüm yapılandırmalara eşit dağılır. Ardışık koşulsaydı en son ölçülen ortam sistematik olarak yavaş görünürdü.
5) **Tek iş parçacığı.** Gerekçe hız değil kararlılıktır (Bölüm VI-B).
6) **İki ayrı dağılım karıştırılmaz.** Koşu içi dağılım (bir koşudaki yüzlerce pencerenin p50/p95/p99'u) sistemin en kötü durum davranışını; koşu arası yayılım (aynı deney tekrarlanınca medyanın oynaması) ölçümün güven aralığını verir.
7) **Pencere gecikmesi $\neq$ hesaplama gecikmesi.** 10 saniyelik pencere ve 5 saniyelik güncelleme aralığı verinin *toplanma* süresidir; bu rapor *hesaplama* süresini ölçer. İkisi her tabloda ayrı tutulur.
8) **Her sonuç JSON'a yazılır**; tablolar JSON'dan üretilir, elle sayı taşınmaz.

C. Koşu envanteri

Tablo V bu raporda kullanılan ölçüm kümelerini listeler.

Tablo V
RAPORDAKI ÖLÇÜM KÜMELERI

Küme	İçerik	Ölçek
Tek süreç	Aşama bazlı profil, `native` yol	S11+S14, 2123 pencere
Kıyas	İplik taraması, ardışık düzen karşılaştırması	S11, 4 tur × 587 pencere
Geri döngü	Yedi metrik, tek ve iki istemci	S11, 10 dk / S11+S14
Sis	Beş XAI durumu, uçtan uca	S11, 600 tik, 44 ölçülen pencere
Yerleşim	Uç–sis, dönüşümlü	S11, 3 tur × 600 tik
XAI tarama	17 yapılandırma, GPU	40 pencere (duyarlılık: 10)

Tablo VI
AŞAMA BAZLI HESAPLAMA SÜRESI (S11+S14, `NATIVE` YOL, NEDENSEL NORMALIZASYON, 2123 PENCERE, 30 ISINMA PENCERESI HARIÇ, TEK IPLIK)

Aşama	ort.	medyan	p95	p99
Yeniden örnekleme	1,507	1,378	2,328	3,259
Ön işleme	0,251	0,218	0,401	0,924
Tensör hazırlığı	0,159	0,141	0,249	0,513
Çıkarım	2,951	2,682	3,997	5,720
Son işleme	0,108	0,086	0,171	0,380
Toplam	**5,034**	**4,689**	**6,658**	**9,170**

Bütün değerler milisaniyedir. Seğirme (ardışık mutlak fark ortalaması) 1,155 ms; işlem CPU'su ort. %90,1; RSS ort. 470,2 MB, tepe 558,0 MB.

VI. SONUÇLAR

A. Aşama bazlı hesaplama profili

Tablo VI, tek süreçli `native` yolda, nedensel normalizasyonla ölçülen aşama sürelerini verir. Toplam hesaplama gecikmesi medyanı 4,69 ms, p95 6,66 ms'dir. En pahalı iki aşama çıkarım (2,68 ms medyan) ve yeniden örneklemedir (1,38 ms medyan).

Bu profil, sistemin hesap tarafının ne kadar ucuz olduğunun temel kanıtıdır: 640×14'lük bir pencere, tek iş parçacığında 5 ms'nin altında sınıflandırılmaktadır. Bu sayı, aynı pencerenin *açıklanmasının* maliyetiyle (Bölüm VI-G) karşılaştırıldığında iki mertebelik fark ortaya çıkmaktadır.

Tablo VII
İŞ PARÇACIĞI TARAMASI (S11, 4 DÖNÜŞÜMLÜ TUR, KOŞU IÇI MEDYANLARIN MEDYANI)

İplik	Toplam (ms)	Yayılım	VK	p95 (ms)
1	**3,397**	**%2,9**	**%1,2**	4,980
2	3,933	%14,7	%6,0	5,774
4	3,684	%10,7	%4,5	5,508

VK: değişim katsayısı. Üç yapılandırmada sınıflandırma sonucu birebir aynıdır (doğruluk 0,8586), yani iplik sayısı yalnızca zamanlamayı etkiler.

Tablo VIII
ARDIŞIK DÜZEN KARŞILAŞTIRMASI (S11, 4 DÖNÜŞÜMLÜ TUR, TEK IPLIK)

Yol	Yen. ör.	Ön işl.	Çıkarım	Toplam	p95
`prepared`	—	0,580	2,969	3,971	6,349
`native`	1,573	0,252	3,039	5,502	7,951

Bütün değerler milisaniyedir. Koşu arası yayılım: `prepared` %9,4, `native` %8,1.

B. Ölçümün tekrarlanabilirliği

Tek bir koşunun sonucu bu makinede güvenilir değildir: aynı yapılandırma arka arkaya koşulduğunda değerler yukarı kaymaktadır (işlemci frekans ölçeklemesi). Bu nedenle bütün karşılaştırmalar dönüşümlü tekrarla yapılmıştır.

Tablo VII iş parçacığı sayısının etkisini gösterir. Medyanlar arasındaki fark, koşu arası yayılımın altında kalmaktadır; yani bu iş yükünde iplik sayısı belirleyici değildir. Varsayılanın 1 olmasının gerekçesi hız değil **kararlılıktır**: tek iplikte yayılım %2,9 iken iki ve dört iplikte %10,7–14,7'dir. Bu, izole mikro-kıyaslamaların yanıltıcı olduğunu ve kararın her zaman tam ardışık düzen üzerinde verilmesi gerektiğini gösteren bir örnektir.

C. Yeniden örneklemenin yeri ve bant genişliği

Tablo VIII, yeniden örneklemenin ölçüme dahil edilip edilmemesinin etkisini verir. Yeniden örnekleme tek başına toplamın yaklaşık %28,6'sıdır, yani çıkarımdan sonraki en pahalı aşamadır. İki yol arasındaki %38,6'lık fark, koşu arası yayılımın (%8–9) çok üstünde olduğu için gerçektir.

Doğruluk korunmaktadır. Pencere başına yeniden örnekleme, tüm sinyali bir kerede indirmekle kenar etkisi nedeniyle birebir aynı sonucu vermez, ancak fark ölçülebilir düzeyin altındadır: `prepared` 0,8586 (587 pencere), `native` 0,8574 (589 pencere).

Bant genişliği karşılığı. 500 ms'lik bir tikte ham hızda 11 536 bayt, 64 Hz'e indirilmiş halde 1 792 bayt taşınır. Yani indirgemeyi sunucuda yapmak ağdan **6,4 kat** fazla veri geçirmek demektir. Bu, yerleşim kararının sayısal dayanağıdır: hesabı sunucuya taşımak ağ maliyetini artırır.

D. Ortak yerleşimde yedi metrik

Tablo IX, gerçek sensör hızında, tek istemciyle, S11'in ilk 10 dakikası boyunca geri döngü üzerinden ölçülen yedi metriği verir.

Tablo IX
GERI DÖNGÜDE YEDI METRIK (S11, TEK ISTEMCI, GERÇEK ZAMANLI, 10 DK, 104 ÖLÇÜLEN PENCERE)

Metrik	ort.	medyan	p95	p99
Gecikme	0,909	0,809	1,466	2,707
Kuyruk gecikmesi	0,062	0,045	0,085	0,622
Çalışma süresi	8,273	7,179	10,524	11,268
Yanıt süresi	9,884	8,821	12,698	13,927

Değerler milisaniyedir. Seğirme 3,529 ms. Bant genişliği 184,8 kbps gönderilen, 2,3 kbps alınan, toplam 187,2 kbps. Sunucu içi aşama dökümü (ortalama): yeniden örnekleme 2,211, ön işleme 0,449, tensör 0,324, çıkarım 4,648, son işleme 0,135 ms.

Tablo X
UÇ (ORTAK YERLEŞIM) VE SIS KARŞILAŞTIRMASI (S11, 600 TIK, 3 DÖNÜŞÜMLÜ TUR, AÇIKLAYICI KAPALI)

Metrik	Uç (ortak)	Sis (Wi-Fi)
Gecikme (medyan)	0,928 (%7,0)	4,910 (%44,7)
Gecikme (p95)	2,073	66,179
Kuyruk gecikmesi	0,048	0,028
Çalışma süresi (medyan)	6,344 (%15,4)	**3,372 (%6,3)**
Çalışma süresi (p95)	8,797	4,400
Yanıt süresi (medyan)	**7,880**	10,151
Yanıt süresi (p95)	10,360	74,355
Seğirme	2,221	22,600
Bant genişliği (kbps)	187,17	187,11
Sunucu CPU	%0,574	%0,111
Sunucu RSS (MB)	186,8	209,5
Saat belirsizliği	0,122	1,359

Değerler aksi belirtilmedikçe milisaniyedir.

Doğrulama. Ayrı bir geri döngü koşusunda (iki istemci, S11 ve S14'ün tam kayıtları, 2123 pencere) tek süreçli `native` yol ile istemci–sunucu yolu aynı veride birebir aynı sınıflandırma sonucunu vermektedir: doğruluk 0,8222, stres F1 0,6944, karışıklık matrisi TN=743, FP=184, FN=29, TP=242. Bu, ağ katmanının hesabı bozmadığının kanıtıdır. Tablo IX'teki on dakikalık koşu S11'in yalnızca başını kapsadığı için sınıflandırma açısından bilgi taşımaz; amacı zamanlama ölçümüdür.

Yakalanan bir hata. Tek süreçli `native` yolda, çoğunluk etiketi geçersiz olan pencereler tamamen atlanıyordu; bu, normalizasyon istatistiğinin o pencerelerde hiç güncellenmemesi anlamına geliyordu. Gerçek bir sunucu etiketi görmez, dolayısıyla böyle bir atlama yapamaz. Düzeltildikten sonra doğruluk 0,7674'ten 0,8222'ye yükselmiş ve iki yol birbirine eşitlenmiştir. Geçersiz etiketli pencereler artık baştan sona işlenmekte, yalnızca sınıflandırma raporundan çıkarılmaktadır.

E. Uç–sis yerleşim karşılaştırması

Tablo X, aynı deneyin iki yerleşimde, üç dönüşümlü turla koşulmuş halini verir. Değerler koşu içi medyanların medyanı, parantez içindeki sayılar koşu arası yayılımdır.

Üç gözlem öne çıkmaktadır. Birincisi, **sis düğümü hesabı daha hızlı yapmaktadır** (3,372 ms'ye karşı 6,344 ms): ortak yerleşimde istemci ve sunucu aynı işlemciyi paylaşmakta ve birbirlerini yavaşlatmaktadır. İkincisi, bu kazanç ağ tarafında geri verilmektedir; yanıt süresi medyanı sis lehine değil, aley-

Tablo XI
LIME TARAMA SONUÇLARI (NEDENSEL UZAY, GPU, 40 PENCERE)

Yapılandırma	ort.	p95	Sadakat	Mono.	Duyarl.	RSS
Aşama 1 — örnek sayısı (10 dilim, kw 0,25)						
250 örnek	105,3	211,4	0,2219	0,5925	0,0274	1186
500 örnek	104,3	162,8	0,2302	0,6025	0,0266	1203
1000 örnek	245,6	376,3	**0,2333**	0,5938	0,0264	1204
Aşama 2 — bölge sayısı (500 örnek, kw 0,25)						
5 dilim	**67,5**	**71,9**	0,2180	**0,6175**	**0,0217**	1205
10 dilim	151,1	268,1	0,2302	0,6025	0,0266	1205
20 dilim	172,9	353,4	0,2375	0,5862	0,0357	1206
Aşama 3 — çekirdek genişliği (500 örnek, 20 dilim)						
kw 0,125	104,8	159,4	0,1887	**0,6700**	**0,0147**	1206
kw 0,25	181,1	358,0	0,2375	0,5862	0,0357	1206
kw 0,50	152,8	344,5	**0,2390**	0,5813	0,0365	1206

Süreler ms, RSS MB. Kendi-kararsızlığı bütün LIME yapılandırmalarında tam olarak 0,0'dır: maske tohumu sabit olduğu için yöntem deterministiktir ve ölçülen duyarlılık yalnızca girdi gürültüsünden gelir.

Tablo XII
SHAP TARAMA SONUÇLARI (NEDENSEL UZAY, GPU, 40 PENCERE, GRADIENTEXPLAINER)

Yapılandırma	ort.	p95	Sadakat	Mono.	Duyarl.	RSS
Aşama 1 — arka plan boyutu (n=200, rastgele)						
10	192,3	232,7	0,2038	**0,6263**	**0,1119**	1407
50	207,1	247,7	0,2212	0,6150	0,1003	1409
100	204,4	252,8	0,2243	0,5938	0,1011	1411
Aşama 2 — örnek sayısı (arka plan 100, rastgele)						
50	**46,5**	**54,9**	0,2214	0,5950	0,1083	1413
200	204,9	249,4	0,2243	0,5938	0,1011	1416
400	402,2	487,7	**0,2246**	0,6025	0,1032	1468
Aşama 3 — arka plan seçimi (100, n=200)						
rastgele	198,4	234,7	0,2243	0,5938	0,1011	1413
k-ortalama	199,3	240,5	**0,2302**	0,5625	0,1184	1406

Süreler ms, RSS MB. Kendi-kararsızlığı $\approx 10^{-8}$ mertebesindedir; tohum sabitlemesi sayesinde yöntem pratikte deterministiktir.

hine çıkmaktadır (10,151'e karşı 7,880 ms). Üçüncüsü, Wi-Fi'ın kuyruk davranışı p95'te dramatiktir: yanıt süresi p95'i 74 ms'ye, seğirme 22,6 ms'ye çıkmaktadır ve koşu arası yayılım %112'ye ulaşmaktadır. Bant genişliği her iki yerleşimde aynıdır, beklendiği gibi.

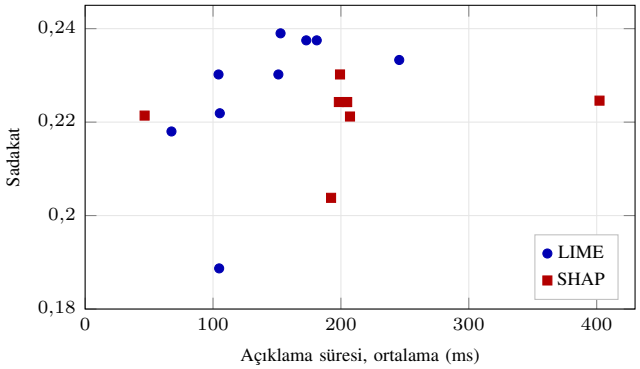
F. Açıklayıcı hiperparametre taraması

Tarama, sunucunun gördüğü girdi uzayında (nedensel normalizasyon) ve GPU üzerinde koşulmuştur. **Kalite ölçütleri donanımdan bağımsızdır ve bu tablolardan alınır; süre değerleri GPU'ya aittir** ve nihai süre tablosu Bölüm VI-G'den gelir. Bu ayrım kritiktir: aynı yapılandırmanın CPU süresi bir mertebe daha büyüktür.

Taramada tek faktör değiştirme (OFAT) yaklaşımı kullanılmış, her aşamanın kazananı bir sonraki aşamanın varsayılanı olmuştur. Kalite, 40 pencere üzerinde; duyarlılık, maliyeti nedeniyle 10 pencere $\times$ 3 deneme üzerinde hesaplanmıştır.

Şekil 2 bu iki tabloyu kalite–gecikme düzleminde birleştirir. Üç bulgu öne çıkmaktadır:

1) **Kalite doyuma erken ulaşmaktadır.** LIME'da örnek sayısını 250'den 1000'e çıkarmak sadakati yalnızca %5,1 artırırken gecikmeyi 2,3 katına çıkarmaktadır.



Şekil 2. Açıklama kalitesine karşı açıklama süresi (GPU, nedensel uzay). Sol üst köşe tercih edilir. Her iki yöntemde de kalite dar bir bantta toplanırken süre bir mertebe değişmektedir.

SHAP'ta örnek sayısını 50'den 400'e çıkarmak sadakati %1,4 artırırken gecikmeyi 8,6 katına çıkarmaktadır. *Pareto cephesi dikleşmektedir*: ucuz çalışma noktaları neredeyse bedavadır.

2) **İki yöntemin kararlılığı aynı mertebede değildir.** LIME'ın duyarlılığı 0,015–0,036, SHAP'ınki 0,100–0,118 aralığındadır; yani girdiye eklenen küçük gürültüye karşı LIME bu kurulumda üç ilâ yedi kat daha kararlıdır. Bu, bitirme projesindeki çevrimdışı sıralamanın tersidir ve nedenlerinden biri bölge tabanlı LIME'ın sabit tohumla deterministik hale getirilmiş olmasıdır.
3) **Bellek ayak izi yöntem seçimine bağlıdır.** SHAP, arka plan kümesini bellekte tuttuğu için LIME'dan yaklaşık 200 MB fazla yer kaplamaktadır (1406–1468 MB'ye karşı 1186–1206 MB, tarama ortamında).

Metodolojik bir karşı örnek. Tarama önce sızıntılı (denek bazlı) normalizasyon uzayında koşulmuş, sonra nedensel uzayda tekrarlanmıştır. İki ölçüm yan yana konduğunda sızıntılı ölçümün XAI'yi olduğundan iyi gösterdiği görülmektedir: LIME'ın sadakati 0,2476'dan 0,2333'e düşmekte, duyarlılığı 0,0174'ten 0,0264'e çıkmaktadır. Yani açıklayıcıyı, dağıtımda hiç görmeyeceği bir girdi dağılımı üzerinde değerlendirmek iyimser bir kalite tahmini üretir. Bu, XAI değerlendirmesinin sunucunun gerçekten gördüğü girdi uzayında yapılması gerektiğinin doğrudan kanıtıdır.

Bu taramaya dayanarak dört çalışma noktası dondurulmuş ve sunucuya gömülmüştür (Tablo XIII). İki maliyet noktası kasıtlıdır: seçici açıklamanın kazancı, açıklama pahalılaştıkça büyür.

G. Sis düğümünde uçtan uca açıklama maliyeti

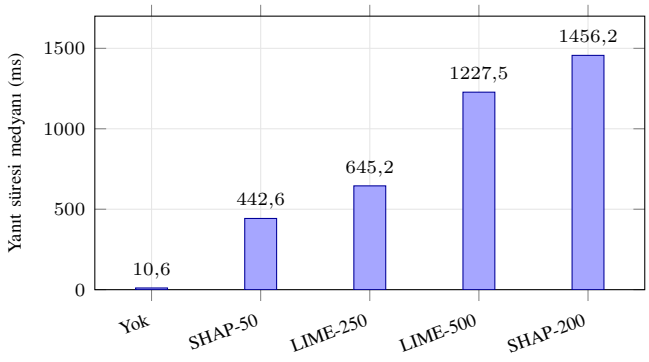
Bu, raporun ana sonucudur. Beş durum aynı koşullarda (S11, tek istemci, 600 tik, Wi-Fi, 44 ölçülen pencere, saat farkı 60 saniyede bir yeniden ölçülerek) uçtan uca koşulmuştur.

Tablo XIV ve Şekil 3 üç sonuç vermektedir:

1) **Açıklama, sistemin baskın maliyetidir.** Açıklayıcı kapalıyken yanıt süresi medyanı 10,6 ms'dir; en pahalı yapılandırmada 1456,2 ms, yani **137 kat**. Sunucu içi aşama

Tablo XIII
SUNUCUYA GÖMÜLEN AÇIKLAYICI YAPILANDIRMALARI

Ad	Yöntem	Yapılandırma
`lime`	LIME	500 örnek, 20 dilim, kw 0,5
`lime_ucuz`	LIME	250 örnek, 20 dilim, kw 0,5
`shap`	SHAP	arka plan 100 (k-ortalama), n=200
`shap_ucuz`	SHAP	arka plan 100 (k-ortalama), n=50



Şekil 3. Sis düğümünde yanıt süresi medyanı. Açıklayıcı kapalıyken 10,6 ms olan yanıt, en pahalı yapılandırmada 137 katına çıkmaktadır.

dökümünde açıklama, çalışma süresinin %99,6'sını oluşturmaktadır (1426,2 / 1431,1 ms). Çıkarımın kendisi hâlâ 2–3,4 ms'dir; yani modelin maliyeti açıklamanın yanında ölçüm gürültüsü mertebesindedir.

2) **Ucuz çalışma noktaları gerçek zamanlılık sınırının altındadır.** ShaTS'in [8] koyduğu 1 s/pencere sınırına göre SHAP (n=50, 442,6 ms) ve LIME (250 örnek, 645,2 ms) uygundur; pahalı yapılandırmalar medyanda ve p95'te bu sınırı aşmaktadır. Beş saniyelik güncelleme aralığı bütçesine göre bakıldığında ucuz noktalar bütçenin %9–13'ünü, pahalı noktalar %25–29'unu tüketmektedir — tek kullanıcıda. Dört kullanıcıda pahalı yapılandırma bütçeyi aşacaktır; seçici açıklamanın gerekçesi tam buradadır.
3) **Bellek, kısıtlı donanımda bağlayıcı olabilir.** RSS tepe değeri 210 MB'den 464 MB'ye çıkmaktadır. 2 GB bellekli bir Raspberry Pi'de bu sıkışacaktır; en az 4 GB gerekmektedir. Artışın kaynağı ikilidir: SHAP'ta bellekte tutulan arka plan kümesi, LIME'da yüzlerce perturbasyonun tek partide oluşturulması.

Tutarlılık denetimi. Gecikme beş koşuda da 4,3–5,3 ms bandında kalmaktadır; yani açıklayıcı seçimi ağ metriklerini etkilememektedir. Bu beklenen davranıştır ve ölçümün kendi içinde tutarlı olduğunun göstergesidir: açıklayıcı sunucu tarafında çalıştığı için taşıma katmanına dokunmaz.

Kayıt boşluğu ve düzeltmesi. Bu koşular alındığında hangi açıklayıcının kullanıldığı yalnızca dosya adında saklanıyordu; sunucu bu bilgiyi istemciye göndermiyordu. Bu, sonuçların yeniden üretilebilirliği açısından bir eksikti ve sonradan giderilmiştir: sunucu artık kapanış istatistiklerinde yöntem adını, eşiği, açıklayıcı yapılandırmasını ve ısınma süresini de göndermektedir.

H. Sınıflandırma başarımının ölçüm yolundan bağımsızlığı

Tablo XV, aynı modelin farklı ölçüm yollarındaki sınıflandırma sonucunu toplar. İki gözlem önemlidir.

Birincisi, **ağ katmanı hesabı bozmamaktadır**: tek süreçli ve istemci–sunucu yolları birebir aynı karışıklık matrisini vermektedir.

İkincisi, **düşüş modelin değil normalizasyon kısıtının sonucudur**. Çevrimdışı 0,9361 değeri, deneğin tüm kaydının istatistiğiyle, yani geleceğe sızarak elde edilmiştir. Nedensel normalizasyonla 0,8222'ye, deneğe hiç uyarlanmayan sabit istatistikle 0,6996'ya düşmektedir. Aradaki 12 puanlık fark, kişiselleştirmenin gerçek zamanlı bir sistemde ne kadar değer taşıdığının doğrudan ölçüsüdür.

I. Mikrodenetleyici fizibilitesi

Açıklama maliyeti sunucuda ölçüldükten sonra doğal bir soru kalmaktadır: çıkarım giyilebilir cihazın içinde yapılabilir mi? Yapılabilirse uç ile sis arasında seçim yapma sorunu ortadan kalkar. Bu, donanım olmadan katman katman parametre, aktivasyon belleği, tepe RAM ihtiyacı ve çarpma-toplama (MAC) sayısı hesaplanarak analiz edilmiştir.

Sonuç nettir: **darboğaz hız değil bellektir**. Pencere başına 14,50 milyon MAC gerekirken bütçe 5000 ms'dir (güncelleme aralığı). En yavaş senaryo olan Cortex-M4 @168 MHz float32'de tahmini süre 287,7 ms, yani bütçenin %5,8'idir; Cortex-M7 @480 MHz int8'de 12,1 ms, yani %0,2'dir. Buna karşılık float32 ağırlıklar yalnızca STM32H743 ve U575 sınıfı cihazlara, int8 ağırlıklar ise F407 ve üzerine sığmaktadır; F103 sınıfı hiçbir biçimde yetmemektedir.

Bu analiz kâğıt üstündedir. Cihaza indirmek için ONNX aktarımı, STM32Cube.AI ya da TensorFlow Lite Micro ile kod üretimi, int8 nicemleme ve doğruluk kaybı ölçümü, ön işlemenin (700 Hz'den 64 Hz'e indirgeme ve nedensel z-skor) porte edilmesi ve cihaz üstü zaman ölçümü gerekmektedir.

VII. TARTIŞMA

Açıklama maliyeti, model maliyetinin iki mertebe üzerindedir. Bu, raporun en net bulgusudur. 49 890 parametreli bir modelin çıkarımı 2–3 ms sürerken, aynı pencerenin açıklanması 390–1426 ms sürmektedir. Literatürdeki "gerçek zamanlı kullanıma uygundur" iddialarının büyük çoğunluğu yalnızca çıkarım süresine bakmaktadır; açıklama katmanı eklendiğinde bu iddialar test edilmemiş varsayımlara dönüşmektedir.

Kalite doyuma erken ulaşmakta, maliyet ulaşmamaktadır. Tarama tablolarında sadakat değerleri 0,19–0,24 gibi dar bir banttayken süre 46,5 ms ile 402,2 ms arasında değişmektedir. Bu asimetri, ucuz çalışma noktalarının pratikte neredeyse bedava olduğu anlamına gelir ve hiperparametre taramasının *süreyle birlikte* yapılmasının niçin gerektiğini gösterir. Yalnızca kaliteye bakan otomatik bir seçim, bu taramada her

Tablo XIV
SIS DÜĞÜMÜNDE BEŞ XAI DURUMUNUN UÇTAN UCA ÖLÇÜMÜ (S11, TEK ISTEMCI, 600 TIK, WI-FI, 44 ÖLÇÜLEN PENCERE, HER KOŞU ≈5 DAKIKA)

Açıklayıcı	Yanıt medyan	Yanıt p95	Çalışma medyan	Açıklama medyan	Açıklama p95	Gecikme medyan	Sunucu CPU	Sunucu RSS tepe
Yok	**10,6**	42,2	3,5	—	—	4,5	%0,0	210,4
SHAP (n=50)	442,6	574,0	394,1	390,4	460,5	4,3	%5,0	422,3
LIME (250 örnek)	645,2	802,5	588,1	584,0	650,6	5,3	%10,8	442,4
LIME (500 örnek)	1227,5	1407,1	1158,1	1154,2	1295,9	5,0	%22,8	449,2
SHAP (n=200)	**1456,2**	1548,5	1431,1	1426,2	1465,0	4,5	%25,9	464,5

Süreler milisaniye, RSS megabayttır. CPU değeri sunucu sürecinin koşu boyunca ortalamasıdır. Bant genişliği beş durumda da 186,7–187,2 kbps aralığındadır. Kuyruk gecikmesi medyanı 0,029–0,030 ms'dir.

Tablo XV
SINIFLANDIRMA BAŞARIMI, ÖLÇÜM YOLUNA GÖRE

Koşul	Doğruluk	Stres F1	Pencere
Çevrimdışı, denek bazlı	0,9361	—	—
Tek süreç, `running`	0,8222	0,6944	1198
İstemci–sunucu, `running`	0,8222	0,6944	1198
Tek süreç, `fixed`†	0,6996	0,4676	1175

† Bu satır, yeniden örneklemenin ölçüm dışında bırakıldığı ve geçersiz etiketli pencerelerin atlandığı önceki (`prepared`) ardışık düzen döneminden gelmektedir; `native` yolda `fixed` normalizasyonla bir koşu henüz yapılmamıştır. Diğer satırlarla birebir karşılaştırılmamalı, yalnızca kişiselleştirme etkisinin mertebesi olarak okunmalıdır.

Tablo XVI
MIKRODENETLEYICI GEREKSINIMLERI (10 S PENCERE, 49 890 PARAMETRE, PENCERE BAŞINA 14,50 MILYON MAC)

Veri tipi	Ağırlık (Flash)	Tepe RAM	Giriş tamponu
float32	194,9 KB	320,0 KB	35,0 KB
float16	97,4 KB	160,0 KB	17,5 KB
int8	48,7 KB	80,0 KB	8,8 KB

Tepe aktivasyon ikinci evrişim bloğunun BatchNorm katmanındadır (81 920 eleman): 128 kanal × 320 uzunluk.

aşamada en pahalı yapılandırmayı seçerdi; bu nedenle nihai seçim, kalite–gecikme tablosuna bakılarak elle yapılmıştır.

Çevrimdışı sıralama gerçek zamanda korunmayabilir. Bitirme projesinde SHAP en kararlı yöntemdi (duyarlılık 0,0038'e karşı LIME 0,0116). Bu kurulumda, nedensel uzayda ve bölge tabanlı LIME ile sıralama tersine dönmüştür (LIME 0,015–0,036, SHAP 0,100–0,118). İki ölçüm farklı modeller, farklı girdi uzayları ve farklı LIME uygulamaları üzerinde yapıldığı için doğrudan karşılaştırılamaz; ancak bulgu, "çevrimdışı en iyi olan yöntemin gerçek zamanda da en iyi olacağı" varsayımının sınanması gerektiğini göstermektedir.

Yerleşim kararı tek bir metrikle verilemez. Sis düğümü hesabı daha hızlı yapmakta (3,4'e karşı 6,3 ms) ama Wi-Fi gecikmesi ve seğirmesi bu kazancı geri almaktadır. Aynı zamanda ham sinyali sunucuya göndermek, indirgenmiş sinyale göre 6,4 kat bant genişliği maliyeti getirmektedir. Karar, hangi metriğin uygulamada bağlayıcı olduğuna bağlıdır.

Ölçüm altyapısının kendisi bir katkıdır. Bu çalışmada üç ayrı ölçüm hatası yakalanmış ve düzeltilmiştir: (i) 15,6 ms çözünürlüklü saatin gecikmeyi sıfır okuması, (ii) kuyruğun olmaması nedeniyle kuyruk gecikmesinin gecikme içinde gizlenmesi, (iii) etiketi geçersiz pencerelerin atlanması nedeniyle normalizasyon istatistiğinin güncellenmemesi. Üçü de sessiz hatalardı; sonuçlar makul görünüyor ama yanlıştı. Gerçek zamanlı ölçüm yapan çalışmaların bu tür denetimleri açıkça raporlaması gerektiğini düşünüyoruz.

VIII. SINIRLILIKLAR

1) **Emülasyon, canlı sistem değil.** Sinyal gerçek sensörden değil, WESAD kaydından gerçek hızda yeniden oynatılmaktadır. Referans çalışma [9] da DREAMER'ı aynı biçimde akıtmıştır; yöntemin savunulabilirliği buna dayanır.
2) **Sis düğümü kaynak kısıtlı değildir.** İkinci makine 12 çekirdekli bir masaüstü sınıfı işlemcidir. Ölçülen şey *dağıtık yerleşim*dir, *kaynak kısıtlı sis düğümü* değil. Kısıtlı mod (tek çekirdeğe kilitleme + tek iplik) altyapıda hazırdır ancak bu rapordaki sayılar kısıtsız modda alınmıştır.
3) **İki tutulmuş denek.** S11 ve S14 dışındaki denekler modelin eğitiminde kullanılmıştır. Eşik ve kalibrasyon çalışmaları için çapraz denek protokolü (S11'de kalibre et, S14'te ölç ve tersi) tasarlanmış fakat henüz koşulmamıştır.
4) **Sis koşularındaki sınıflandırma sayıları anlamlı değildir.** Tablo XIV'deki koşular S11'in ilk beş dakikasını kapsamaktadır ve bu aralıkta stres etiketi hiç bulunmamaktadır (42 etiketli pencerenin tamamı stres dışı). Bu koşuların amacı zamanlama ölçümüdür; sınıflandırma başarımı Tablo XV'den okunmalıdır.
5) **Bulut ayağı yoktur.** Uç–sis karşılaştırması yapılmış, bulut yerleşimi bütçe nedeniyle atlanmıştır. Altyapı bunu tek bir adres parametresiyle desteklemektedir.
6) **Wi-Fi'da gecikme belirsizliği yüksektir.** Tek yönlü gecikmenin hata payı ±1–10 ms'dir ve ölçülen değerle aynı mertebeye çıkabilir. Çalışma süresi, kuyruk gecikmesi, yanıt süresi ve seğirme bundan etkilenmez; gecikme sütunu dikkatle okunmalıdır. Ethernet üzerinde tekrar yapılmamıştır.
7) **Referans çalışmanın birincil kaynağı doğrulanamamıştır.** [9]'in erişilebilir bir kaydı bulunamamıştır; bu çalışmayla yapılan metrik karşılaştırması, künye ve sa-

yılar birincil kaynaktan doğrulanmadan nihai metne alınmamalıdır.

8) **Tek model.** Açıklama maliyeti yalnızca TemporalCNN üzerinde ölçülmüştür. TranSensFusers gibi daha büyük modellerde hem çıkarım hem de gradyan tabanlı açıklama maliyeti artacaktır; oran değişebilir.

IX. Devam Eden İşler

Seçici açıklama mekanizması sunucuya entegre edilmiş, çalıştığı doğrulanmış ve iki uç durumu ölçülmüştür. Aşağıdaki adımlar planlanmış fakat henüz tamamlanmamıştır:

1) **Güven kalibrasyonu.** Güvenilirlik diyagramı ve beklenen kalibrasyon hatası (ECE); gerekirse tek parametreli sıcaklık ölçekleme. Kalibrasyon, kalibrasyon deneğinde öğrenilip test deneğinde uygulanacaktır.
2) **Eşik taraması.** $\tau \in \{0{,}60,\ 0{,}70,\ 0{,}80,\ 0{,}90\}$ için: açıklanan pencere yüzdesi, yakalanan hata yüzdesi (yanlış sınıflanan pencerelerin kaçında açıklama tetiklendi), pencere başına ortalama hesap, p95 gecikme, CPU ve RSS. Bu, "belirli bir açıklama kapsamında hataların ne kadarı açıklandı" çalışma eğrisini verecektir.
3) **Çok istemcili yük.** 1, 2 ve 4 istemciyle kuyruk gecikmesi p95'inin büyümesi. Seçici açıklamanın kazancının asıl görüneceği yer burasıdır: dört kullanıcı $\times$ 400 ms, beş saniyelik bütçenin üçte birini tüketmektedir.
4) **Düşük güvenli pencerelerde açıklama kararsızlığı.** En güçlü itiraza cevap: post-hoc açıklamalar karar sınırına yakın oynaktır ve kapı tam orada tetiklenmektedir. Duyarlılık ölçütü yalnızca düşük güvenli pencerelerde ayrıca hesaplanacaktır.
5) **Model karmaşıklığı ablasyonu.** Mevcut OFAT taramasından derinlik, filtre ve çekirdek varyantlarının F1–gecikme Pareto eğrisi.

X. Sonuç

Bu rapor, çevrimdışı olarak seçilmiş bir fizyolojik stres sınıflandırıcısını gerçek zamanlı bir istemci–sunucu sistemine yerleştirmiş ve açıklanabilirliğin hesaplama maliyetini, taşıma katmanı metrikleriyle aynı bütçede ölçmüştür.

Ana bulgu, açıklama maliyetinin model maliyetini iki mertebe aşmasıdır: ayrı bir makinede, Wi-Fi üzerinden ölçülen yanıt süresi medyanı açıklayıcı kapalıyken 10,6 ms, en pahalı yapılandırmada 1456,2 ms'dir. Sunucu bellek ayak izi 210 MB'den 464 MB'ye çıkmaktadır. Hiperparametre taraması, açıklama kalitesinin dar bir bantta doyuma ulaştığını fakat sürenin bir mertebe değiştiğini göstermiştir; bu asimetri, ucuz çalışma noktalarının (SHAP 442,6 ms, LIME 645,2 ms) literatürdeki bir saniyelik gerçek zamanlılık sınırının altında kalmasını sağlamaktadır.

Bu sayılar, güven eşikli seçici açıklamanın niçin gerekli olduğunu niceliksel olarak ortaya koymaktadır: tek kullanıcıda bile pahalı bir açıklayıcı güncelleme aralığı bütçesinin dörtte birini tüketmekte, çok kullanıcılı ya da kaynak kısıtlı senaryolarda ise bütçeyi aşmaktadır. Mekanizma sisteme entegre edilmiş ve uç durumları ölçülmüştür; eşik taraması ve kalibrasyon çalışmaları devam etmektedir.

Kaynaklar

[1] P. Schmidt, A. Reiss, R. Duerichen, C. Marberger ve K. Van Laerhoven, "Introducing WESAD, a multimodal dataset for wearable stress and affect detection," *Proc. 20th ACM Int. Conf. Multimodal Interaction*, 2018, ss. 400–408.

[2] P. Kasnesis, C. Chatzigeorgiou, M. Feidakis, A. Gutierrez ve C. Z. Patrikakis, "TranSenseFusers: A temporal CNN-transformer neural network family for explainable PPG-based stress detection," *Biomedical Signal Processing and Control*, c. 102, s. 107248, 2025.

[3] M. T. Ribeiro, S. Singh ve C. Guestrin, "'Why should I trust you?' Explaining the predictions of any classifier," *Proc. 22nd ACM SIGKDD*, 2016, ss. 1135–1144.

[4] S. M. Lundberg ve S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in Neural Information Processing Systems*, c. 30, 2017.

[5] M. Sundararajan, A. Taly ve Q. Yan, "Axiomatic attribution for deep networks," *Proc. Int. Conf. Machine Learning (ICML)*, 2017, ss. 3319–3328.

[6] T.-Y. Lin, P. Goyal, R. Girshick, K. He ve P. Dollár, "Focal loss for dense object detection," *Proc. IEEE ICCV*, 2017, ss. 2980–2988.

[7] M. Nauta *ve ark.*, "From anecdotal evidence to quantitative evaluation methods: A systematic review on evaluating explainable AI," *ACM Computing Surveys*, c. 55, sy. 13s, 2023.

[8] M. Franco de la Peña *ve ark.*, "ShaTS: A Shapley-based method for time-series explainability in industrial IoT," arXiv:2506.01450, 2025.

[9] E. Erzurumluoğlu *ve ark.*, "Emotion recognition on a fog computing architecture," *Proc. Int. Conf. Advanced Communication Technology (ICACT)*, 2025.

[10] M. Basaran ve F. Dressler, "XAI-on-RAN: Explainability overhead in live O-RAN control loops," arXiv:2511.17514, 2025.

[11] T. Taguta *ve ark.*, "Conditional SHAP for on-device cold-chain monitoring: A 24-day field deployment," arXiv:2609.14036, 2026.

[12] D. Das *ve ark.*, "Explainable activity recognition from wearable sensors," *ACM Trans. Interactive Intelligent Systems*, 2021; arXiv:2105.09787.

[13] A. Warnecke, D. Arp, C. Wressnegger ve K. Rieck, "Evaluating explanation methods for deep learning in security," *Proc. IEEE European Symp. on Security and Privacy (EuroS&P)*, 2020.

[14] N. Jethani, M. Sudarshan, I. Covert, S.-I. Lee ve R. Ranganath, "FastSHAP: Real-time Shapley value estimation," *Proc. Int. Conf. Learning Representations (ICLR)*, 2022.

[15] A. Almadhor *ve ark.*, "Explainable deep learning for multimodal physiological stress and emotion recognition," *Frontiers in Bioengineering and Biotechnology*, 2025.

[16] N. El Rashidy *ve ark.*, "An explainable fog-based emotion recognition framework," *Frontiers in Computer Science*, c. 7, 2025.

[17] L. M. Paes, D. Wei ve F. P. Calmon, "Selective explanations," arXiv:2405.19562, 2024.

[18] S. Teerapittayanon, B. McDanel ve H. T. Kung, "BranchyNet: Fast inference via early exiting from deep neural networks," arXiv:1709.01686, 2017.

[19] K. Berestizshevsky ve G. Even, "Dynamically sacrificing accuracy for reduced computation: Cascaded inference based on softmax confidence," arXiv:1805.10982, 2018.

[20] A. Artelt, R. Visser ve B. Hammer, "Model agnostic local explanations of reject," *Neurocomputing*, c. 558, 2023; arXiv:2205.07623.

[21] S. Cindioğlu ve M. Eldemery, "Explainable artificial intelligence for stress detection using physiological data," Bitirme Projesi, Yıldız Teknik Üniversitesi, Bilgisayar Mühendisliği Bölümü, Ocak 2026.